

Grocery Sales BI Dashboard

Business Intelligence, Data Mining et Prévision du chiffre d'affaires

Réalisé par :

- **Amami Yousra**
- **Hamdan Kaouthar**
- **Zarqi Ezzoubair**
- **EL gharib Mahmoud**
- **EL Attar Mohamed**

Encadré par :

- **Pr. Salma Chrit**



Contexte du projet

Les entreprises de distribution alimentaire génèrent des volumes importants de données transactionnelles brutes, difficiles à exploiter directement. Ce projet vise à transformer ces données en tableaux de bord interactifs, en insights métier, en associations produits et en prévisions de chiffre d'affaires, pour faciliter la prise de décision.



Objectifs du Projet

01

Préparer et nettoyer les données de ventes alimentaires brutes pour assurer leur qualité et cohérence.

02

Construire un entrepôt de données en schéma en étoile (fact_sales + dimensions) sous PostgreSQL.

03

Automatiser le chargement ETL avec Apache Hop : tri, déduplication et alimentation des tables.

04

Créer des tableaux de bord interactifs Power BI avec mesures DAX et filtres dynamiques.



Objectifs du projet (suite)

Cette page présente les deux derniers objectifs du projet, axés sur l'exploitation analytique avancée des données de ventes alimentaires grâce au Data Mining et au Machine Learning.




Appliquer l'analyse de panier (Basket Analysis) pour identifier les associations produits fréquemment achetés ensemble et optimiser le cross-selling.



Prévoir le chiffre d'affaires futur avec des modèles de Machine Learning (Holt-Winters, XGBoost, Random Forest, SARIMA) pour anticiper les ventes.



Données Utilisées



Ventes & Transactions

Données transactionnelles brutes : identifiant vente, date, montant, quantité, remise. Chaque vente est reliée à un produit, un client et un employé.



Produits, Catégories & Géographie

Référentiel produits avec catégories et sous-catégories. Données géographiques : villes et pays pour l'analyse territoriale des ventes.




Clients & Employés

Profils clients (âge, ville, fréquence d'achat) et données employés (poste, région, performance). Dimensions clés du schéma en étoile.

Architecture Globale

Cette figure présente la démarche générale suivie dans le projet. Elle illustre le passage progressif des données brutes de ventes alimentaires vers une solution décisionnelle complète. Les données sont d'abord nettoyées et préparées avec Python, puis chargées avec Apache Hop dans un entrepôt PostgreSQL organisé en schéma en étoile. Ensuite, Power BI permet de créer des tableaux de bord interactifs et des mesures DAX. Enfin, une couche analytique avancée complète le projet avec l'analyse du panier et la prévision du chiffre d'affaires.



Pipeline ETL avec Apache Hop

01

Extract

Lecture du fichier CSV dénormalisé contenant les ventes, produits, clients, employés et catégories.

02

Transform

Tri, suppression des doublons et sélection des colonnes nécessaires pour alimenter les dimensions.

03


Load

Insertion des dimensions dans PostgreSQL, puis chargement massif de fact_sales avec PostgreSQL Bulk Loader.

Dans notre projet, Apache Hop joue le rôle de moteur ETL. Il prend en entrée le fichier `grocery_sales_denormalized.csv`, puis le divise en plusieurs branches. Les dimensions sont d'abord triées, dédoublées et chargées dans PostgreSQL. Ensuite, la table `fact_sales` est alimentée avec un chargement massif, car elle contient le plus grand volume de données. Cette organisation respecte les clés étrangères et garantit que le modèle en étoile est correctement alimenté.



Pipeline ETL avec Apache Hop



Préparation des Données



Inspection & Nettoyage

Inspection des colonnes et types de données.
Gestion des valeurs manquantes et incohérentes.
Vérification et suppression des doublons.



Transformation des Données

Conversion des dates au format standard.
Normalisation des variables catégorielles.
Génération de variables utiles pour BI et prévision.



Fichier Analytique Dénormalisé

Fusion et consolidation des sources de données.
Création d'un fichier analytique dénormalisé prêt pour l'ETL, Power BI et les modèles ML.




Modélisation Décisionnelle

01

Schéma en étoile : la table de faits `fact_sales` centralise les mesures de vente et est reliée aux dimensions `dim_product`, `dim_category`, `dim_customer`, `dim_employee` et `dim_date`.

02


Ce modèle facilite les agrégations, les filtres dynamiques et le calcul des KPI dans Power BI grâce aux relations entre la table de faits et les dimensions.



Modèle relationnel dans Power BI

Le modèle relationnel Power BI reprend la logique du schéma en étoile. La table fact_sales est reliée aux tables de dimensions afin de permettre les filtres, les agrégations et les mesures DAX.

Dans Power BI, la dimension calendrier est représentée par la table Calendrier.



Tableaux de bord Power BI

Objectif :

Transformer l'entrepôt PostgreSQL en outil interactif d'aide à la décision.

01

Sales Performance

02

Product Performance

03

Customer Performance

04

Employee Performance

05

Basket Analysis



Sales Performance

Question métier :

Comment évoluent les ventes dans le temps et quelles villes contribuent le plus au chiffre d'affaires ?

Points clés :

- 01 Suivi du CA total, des quantités vendues et du nombre de transactions.
- 02 Analyse de la saisonnalité mensuelle et de la croissance annuelle.
- 03 Identification des villes les plus performantes.



Product Performance

Question métier :

Quels produits et catégories contribuent le plus à la performance commerciale ?

Points clés :

- 01 Analyse du chiffre d'affaires par catégorie.
- 02 Identification des top et bottom produits.
- 03 Étude des caractéristiques produit : allergie, résistance et catégorie.




Employee Performance

Question métier :

Quels employés contribuent le plus au chiffre d'affaires ?

Points clés :

- 01 Classement des employés selon le chiffre d'affaires généré.
- 02 Analyse des ventes moyennes par employé.
- 03 Comparaison des performances selon l'âge, le genre et la catégorie d'âge.




Customer Performance

Question métier :

Quels clients génèrent le plus d'activité et comment se répartissent-ils géographiquement ?

Points clés :

- 01 Suivi des clients actifs, du panier moyen et de la fréquence d'achat.
- 02 Classement des meilleurs et moins bons clients.
- 03 Analyse géographique pour orienter les actions de fidélisation.




Data Mining -Basket Analysis

Question métier :

Quels produits sont fréquemment achetés ensemble ?

Points clés :

- 01 Analyse des associations avec Support, Confidence et Lift.
- 02 Identification des paires de produits les plus intéressantes.
- 03 Exploitation possible pour le cross-selling, les promotions et l'organisation des rayons.



Machine Learning : Prédiction du chiffre d'affaires

01 Construction de la série temporelle

Les ventes sont agrégées par mois afin d'obtenir le chiffre d'affaires mensuel.

02 Préparation des données

Création de variables temporelles :

- retards : Lag_1, Lag_2, Lag_3, Lag_12
- moyennes mobiles : 3, 6 et 12 mois
- variables calendaires : mois, trimestre, année

03 Évaluation

La série est séparée chronologiquement en données d'entraînement et de test pour éviter toute fuite d'information.

04 Comparaison des modèles de prédiction

Holt-Winters : MAPE 4.92% | R^2 0.8678

Ensemble pondéré : MAPE 5.27% | R^2 0.8111

XGBoost : MAPE 5.56% | R^2 0.8184

Random Forest : MAPE 11.94% | R^2 0.2128

SARIMA : MAPE 46.76% | R^2 -9.2000

05 Résultat principal

Holt-Winters est le modèle le plus performant. Il capture mieux la tendance et la saisonnalité du chiffre d'affaires, ce qui le rend adapté à la prédiction des ventes dans ce projet.



Conclusion

- Mise en place d'une chaîne BI complète : Python → Apache Hop → PostgreSQL → Power BI.
- Création de tableaux de bord interactifs pour analyser les ventes, produits, clients, employés et paniers.
- Ajout d'une couche Data Mining avec le Basket Analysis pour identifier les associations produits.
- Prédiction du chiffre d'affaires avec plusieurs modèles ML, avec Holt-Winters comme meilleur modèle.
- Le projet transforme des données transactionnelles brutes en un outil d'aide à la décision commerciale.



Merci !

Merci de votre attention — Questions ?